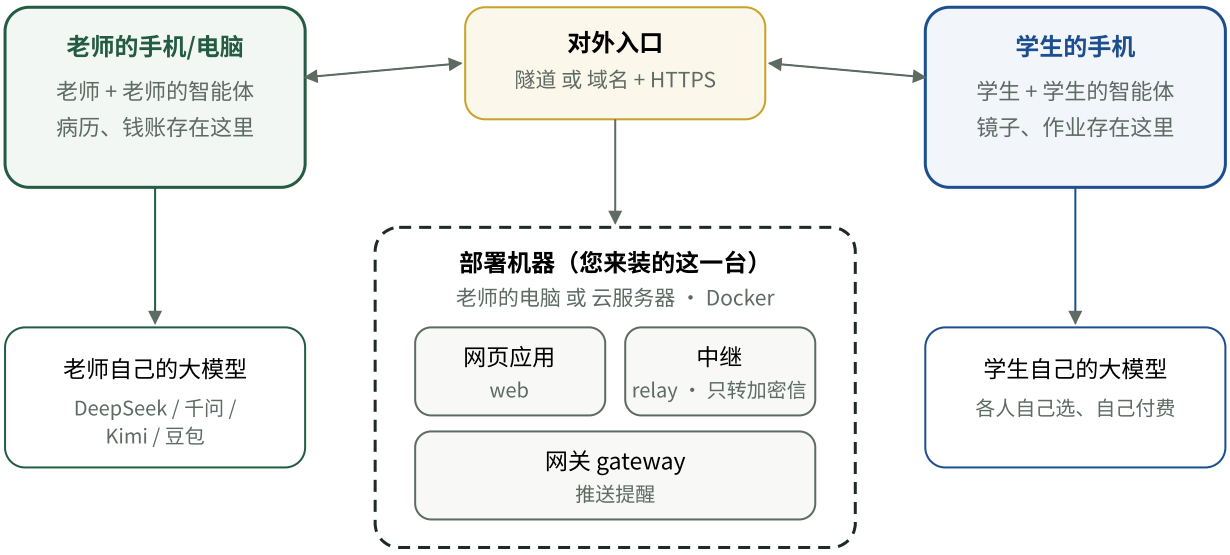
知衡落地手册

写给帮老师把知衡装起来的技术人员 · 2026 年 10 月

知衡不需要说明书：老师和学生打开就能用，用的过程中自己摸索。这份手册只讲一件事——**怎样把它装起来、连起来**。

一、整体是怎么连的



老师和学生的手机经“对外入口”打开网页应用，彼此的消息经中继转发（加密，中继看不到内容）。
大模型由各人的手机直接调用，不经过部署机器。病历、舌象、钱账都存在各自手机上。

每个馆独立一套

阿慈养生馆和小黄运动馆**各装一套**，互不相干。一套里只有一位登记的老师和他邀请的学生。

二、国内网络先处理好

- **代码**：GitHub 公开仓库 `Jordani-Ho/Aster-Ai`，部署文件在 `deploy/home/`。GitHub 慢可下载压缩包。
- **Docker 镜像**：先配好国内镜像加速源。
- **编译**：中继在容器里编译 Rust（10 到 30 分钟），为 crates 配国内镜像；npm 也可配国内镜像。
- **大模型**：不用在服务器上配，老师和学生在应用里各自填自己的钥匙。

三、两种装法，任选一种

	A：老师自己的电脑	B：云服务器
适合	先试用	长期使用
需要	Windows + WSL2 Ubuntu，或一台 Linux 电脑；电脑要一直开着	一台 Linux 云服务器（2 核 4 GB 够用）+ 一个域名
对外入口	隧道（脚本默认用 Cloudflare 临时隧道，网址每次重启会变）	两个子域名 + Caddy 自动 HTTPS，网址固定

两种都先装好：Docker（含 compose）、Node 22、git、curl。

A：老师自己的电脑

```
cd deploy/home
cp .env.example .env
./quick-start.sh        # 最后一行打印手机能打开的网址
./verify.sh             # 六项都应 PASS
```

> Cloudflare 临时隧道在国内可能时快时慢。不稳定时，可换成国内内网穿透服务，把两个地址分别指向 `web:8080`（应用）和 `relay:8080`（中继，需支持 WebSocket）；或改走 B。

B：云服务器

1. 域名下建两个子域名，都解析到服务器：`app.域名`（应用）、`relay.域名`（中继）。
2. 编辑 `deploy/home/.env`：

   ```
   APP_DOMAIN=app.域名
   RELAY_DOMAIN=relay.域名
   VAPID_SUBJECT=mailto:你的邮箱
   ```

3. 生成配置并启动：

   ```
   ./setup.sh
   docker compose up -d --build relay gateway web
   ```

4. 在同一个 Docker 网络里加一个 Caddy，负责 HTTPS 和 WebSocket，服务器只开 80、443：

```
app.域名 {
    reverse_proxy web:8080
}
relay.域名 {
    reverse_proxy relay:8080
}
```

5. 验收：`./verify.sh`。

> B 的反向代理部分还没有在国内实际走过，遇到问题请联系发起人。服务器放在哪里、要不要备案等，请老师和技术人员按当地情况自己判断。

四、装好以后交给老师

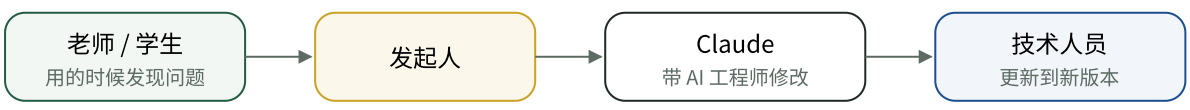
1. 在部署机器上取一次性登记口令：`cat deploy/home/data/teacher-setup-code.txt`，只交给老师本人。
2. 把应用网址发给老师。老师打开 → 选“我是老师” → 接入自己的模型 → 进“管理” → “我是这个社区的老师” → 输入口令。
3. 看到“社区已建立，可以邀请学生”就完成了。接下来老师自己改门面、邀请学生。

五、日常维护

要做的事	命令（在 deploy/home/ 下）
停止（数据保留）	`docker compose down`（A 加 `--profile quick`）
重新启动	A：`./quick-start.sh`；B：`docker compose up -d relay gateway web`
更新到新版本	`git pull` → `docker compose build relay gateway web` → 重新启动 → `./verify.sh`
检查是否正常	`./verify.sh`

- `.env`、`data/` 和登记口令都不要外传，也不要提交到任何仓库。
- 部署机器上只有加密后的消息和推送订阅；病历、舌象、钱账都在老师和学生各自手机里，部署机器坏了也不丢。

六、用起来以后：有问题找谁



- 老师和技术人员**不改代码**。用的过程中觉得哪里不对、哪里不顺、哪个叫法不合适，都直接告诉发起人。
- 装不上、打不开：先跑 `./verify.sh`，把没通过的那一行发给发起人。
- 改好以后会发布新版本，技术人员按“更新到新版本”那一行操作即可。